

Undergraduate Thesis - Public Copy

Incentive Mechanism-Based Defense Against Malicious Participants in Federated Learning

This public copy keeps the thesis body, formulas, figures, and experiment results.
The original identity-and-submission cover is not included in this public export.
The document is shared as a historical undergraduate research record, not as a
current course or graduation-project submission template.

Public Copy Note

Document scope

The original title page and personal submission metadata are omitted.

The technical chapters begin on the following page and are retained for context.

Figures and experiment discussions remain part of the historical research record.

摘 要

在当今信息时代，数据安全和隐私保护日益成为全球关注的焦点，联邦学习（Federated Learning, FL）这一概念应运而生，它实现了在保护个人数据私密性的同时进行有效的协作学习。然而，如何激励参与者公平地贡献数据和计算资源是联邦学习成功实施的关键。本文主要研究联邦学习系统的搭建，并在此系统基础上完成激励机制的设计与实施，采用基于 Shapley 值的声誉激励方法来激励参与者，从而提高模型的整体性能，增强了系统的鲁棒性和安全性。

本文介绍了联邦学习的研究背景及发展现状，并阐述了联邦学习激励机制的研究进展。本文通过构建一个包含多种参数设置的联邦学习系统模型，展示了系统的可运行性和良好的可扩展性，并通过实验验证了模型的有效性。在已实现的联邦学习系统上本文进行了初步改进，使之能够应用激励机制进行激励。在此基础上，本文设计了一个基于 Shapley 值的激励机制，并通过一系列实验对其进行了评估。实验结果表明，该激励机制不仅提升了系统的数据安全性和鲁棒性，还有效地区分了诚实与恶意客户端，为模型聚合提供了更精确的权重参考。本研究的创新之处在于使用声誉参与全局模型的聚合，并将 Shapley 值引入联邦学习的激励机制设计中，为联邦学习中的客户端声誉评估提供了一种新的方法论。通过精确评估客户端的边际贡献，实现了声誉值的动态调整，有效保障了联邦学习系统的整体性能和安全性。未来，本研究可以为其他涉及多方数据共享和计算的应用场景提供理论指导。

关键词:联邦学习；激励机制；Shapley 值

Abstract

In the current information era, data security and privacy protection have increasingly become a global focus. Federated Learning(FL), a concept that has emerged in response to these concerns, enables effective collaborative learning while preserving the privacy of individual data. However, motivating participants to fairly contribute data and computational resources is key to the successful implementation of federated learning. The construction of a federated learning system has been primarily investigated, and based on this system, the design and implementation of an incentive mechanism have been accomplished. A reputation-based incentive method rooted in Shapley values has been employed to motivate participants, thereby enhancing the overall performance of the model and strengthening the robustness and security of the system.

The research background and current developments in federated learning, as well as the advancements in incentive mechanisms within this domain, are presented. By constructing a federated learning system model with various parameter settings, the system's operability and scalability have been demonstrated, and the model's effectiveness has been validated through experimentation. Preliminary improvements on the implemented federated learning system have been made to facilitate the application of incentive mechanisms. Based on this, a Shapley value-based incentive mechanism has been designed and evaluated through a series of experiments. The results indicate that this incentive mechanism not only enhances the system's data security and robustness but also effectively differentiates between honest and malicious clients, providing a more precise weighting reference for model aggregation. The innovation of this research lies in the use of reputation for the aggregation of the global model and the introduction of Shapley values into the design of the incentive mechanism for federated learning, offering a novel methodology for client reputation assessment in federated learning. By precisely assessing the marginal contributions of clients, dynamic adjustment of reputation values is achieved, effectively ensuring the overall performance and security of the federated learning system. This research may provide theoretical guidance for other applications involving multi-party data sharing and computation in the future.

Keywords: federated learning, incentive mechanism, shapley values

目 录

摘 要	I
Abstract	II
第 1 章 绪 论	1
1.1 课题背景及研究的目的和意义	1
1.2 国内外研究现状	3
1.3 本文的主要研究内容	4
1.4 论文组织结构	4
第 2 章 技术背景介绍	6
2.1 联邦学习概述	6
2.1.1 联邦学习的特征	6
2.1.2 联邦学习的分类	7
2.1.3 联邦学习的防御策略	9
2.2 激励机制	10
2.2.1 激励机制分类	11
2.2.2 联邦学习激励机制	11
2.3 联邦学习框架	13
2.4 本章小结	14
第 3 章 联邦学习系统模型搭建	15
3.1 联邦学习系统的构建	15
3.1.1 配置信息	15
3.1.2 训练数据集	16
3.1.3 服务端	16
3.1.4 客户端	17
3.1.5 整合	17
3.2 联邦训练的模型效果	18
3.2.1 联邦训练与集中式训练的效果对比	18
3.2.2 联邦模型与单点训练模型的对比	19
3.3 本章小结	19
第 4 章 应用 Shapley 值激励的 FL 防御方法	21
4.1 基于现有联邦学习系统的初步改进	21

4.1.1	增加预训练环节	21
4.1.2	模拟恶意客户端的攻击	21
4.1.3	引入声誉评估机制	22
4.1.4	使用激励机制的 FL 训练与普通 FL 训练对比	23
4.2	基于 Shapley 值的声誉更新机制	24
4.2.1	使用 Shapley 值评估贡献	24
4.2.2	优化 Shapley 值的计算过程	25
4.2.3	细化声誉值的调整过程	25
4.3	实验结果	26
4.3.1	相同调整因子下不同攻击程度的防御效果对比	26
4.3.2	相同攻击程度下不同调整因子的防御效果对比	28
4.3.3	客户端的 Shapley 值和声誉值变化	29
4.4	本章小结	31
结 论		32
参考文献		33
哈尔滨工业大学本科毕业论文（设计）原创性声明和使用权限		35
致 谢		36

第 1 章 绪 论

1.1 课题背景及研究的目的和意义

在过去的十年里，机器学习技术在人工智能领域实现了飞跃式的发展，在计算机视觉、自然语言处理和推荐系统等方面表现出了出色的性能。这种演变是由三个关键因素促成的：计算能力的增强，使得处理复杂的计算比以前更加容易；数据采集变得比以往更加简单；以及机器学习模型本身的持续优化。基于大数据的训练，机器学习技术在多个行业中取得了成功应用。但是中小企业因无法独立获取大量高精度模型数据而陷入困境，这就需要通过集中化的模型构建方法来整合不同来源的数据。并且随着人工智能技术的广泛应用，社会对数据安全和隐私保护的要求也在不断提高。在这种社会环境下，政府和监管机构纷纷推出新的法律和规定来管理和利用数据，增加了组织间数据共享的难度，产生了数据孤岛的问题。

2016 年，谷歌的 McMahan 等^[1]引入联邦学习的概念来应对这一挑战，这是一种解决数据孤岛问题的有效策略^[2]。




图 1-1 联邦学习的训练过程

联邦学习通过允许多个节点（客户端）协同工作，从而有效解决机器学习中的数据隔离问题。在这种架构中，中央服务器或服务提供商负责协调各个客

户端的合作。每个客户端的数据始终保存在本地，无需将数据直接发送到服务器，这样有效地保护了隐私和数据安全。各客户端利用自身的数据集在本地进行模型训练，并将得到的模型参数上传至中央服务器^[3]。中心服务器将收到的参数汇总，聚合成一个综合模型，并将该模型返回给客户端。如图 1-1 所示，通过多轮迭代，所有客户端参与并完善这一共享模型的训练过程。

与传统的集中式模型训练方法相比，联邦学习可以利用分布在不同设备上的数据进行训练，提高模型的泛化性能。对于数据异构性较强的场景，联邦学习比传统的集中式训练方法有更好的性能。一般来说，联邦学习可以更好地保护数据隐私并降低通信带宽要求^[4]。但它主要是为了防止敏感数据遭受外部攻击，但并不足以防御内部参与者（例如恶意服务器）的攻击^[5]，如图 1-2 所示。恶意行为者可能故意上传不正确或有害的模型参数，或试图窃取其他参与者的数据信息。这些恶意攻击可能会导致模型收敛速度减慢、准确性降低，甚至产生错误的预测结果^[6]。




图 1-2 联邦学习的安全隐患

目前，针对这些安全隐患，联邦学习通常采用的防御性措施包括：差分隐私、同态加密和安全多方计算等。联邦学习的防御方式更偏向于被动的手段进行防御，而不是主动的去进行筛选和剔除恶意的攻击者。传统的 Byzantine-tolerant 算法是基于防御的，有时在联邦学习中会出现准确性下降的情况。性能下降的原因是现有方法采用非针对性防御，是以牺牲诚实客户端为代价来防御攻击者。在这种情况下，主动型的防御措施，如异常检测方法和激

励机制与联邦学习的结合便显得言之有理。

本研究旨在探索联邦学习中激励机制的设计与优化，特别是针对存在恶意客户端攻击的环境下，如何通过激励机制有效防御这些攻击，同时提升模型的训练效果和确保参与者的公平性。本文设计了具体的激励机制实施方案，旨在验证激励机制在提高联邦学习系统抗攻击能力方面的有效性。

通过本研究的深入探讨和系统设计，预期能够提高联邦学习系统在面对恶意攻击时的鲁棒性，同时也为联邦学习激励机制的理论和实践提供了新的视角和方法。这将有助于推动联邦学习技术在更广泛的应用场景中的部署，尤其是在数据安全和用户隐私这些极为重要的领域。

1.2 国内外研究现状

联邦学习的激励机制仍是一个较新的研究领域，关于这一主题的综述性文献相对较少。一些学者已经开始运用契约论和博弈论的方法构建联邦学习的激励框架，旨在通过计算参与者的具体贡献来分配公正的报酬，以促进他们参与模型训练。

目前联邦学习中使用激励机制较多应用于在公平可信的客户端参与方的环境下训练出更好的模型效果。**Kang** 等^[7]在探讨联邦学习中任务分发者与参与者之间的信息不均衡问题时，开发了一种基于契约理论的单一维度评价方法。该方法按用户提供的计算资源多少来加快局部模型训练速度，并据此在联邦学习系统中给予更高的奖励。此外，**Song** 等^[8]引入了基于 **Shapley** 值的用户贡献度指标，该指标通过考量本地数据集、测试集和算法等因素，量化了用户在横向联邦学习任务中的贡献程度。

对于资源有限的情况，**Zhang** 等^[9]结合声誉系统和反向拍卖理论，设计了一种激励机制。在此机制下任务发布者发布任务时，利用客户的竞价和声誉评分来筛选参与的客户，优先选择那些数据质量较高的客户。完成联邦学习训练后，任务发布者会更新客户的声誉评分，并根据其贡献度和声誉来分配奖励。**Zhan** 等^[10]在调整激励策略时，进行了动态优化，采用了建立服务器与边缘节点之间收益关系的 **Stackelberg** 策略博弈，通过寻找纳什均衡点来优化结果。**Hu** 等^[11]通过应用博弈论，把联邦学习中的服务器与用户之间的互动视为一个两阶段 **Stackelberg** 博弈问题，并解析性地求解该博弈的均衡状态。此方法能够识别并奖励那些可能提供高价值隐私保护数据的用户。这种策略帮助确保数据的质量和安全性，同时激励用户分享更有用的信息。

然而，联邦学习面临的挑战之一是如何在存在恶意客户端的情况下保持系统的安全和效率。恶意客户端可能通过数据污染、模型更新攻击等方式破坏学习过程，影响学习结果的准确性和可信度。在这种背景下，将激励机制作为一种防御策略进行探索，显得尤为重要。随着恶意攻击手段的不断进化，探索和发展针对这些威胁的激励防御机制，是确保联邦学习持续发展的重要研究方向。

1.3 本文的主要研究内容

本文的主要研究工作如下：

（1）联邦学习系统的设计与实现：本研究详细介绍了联邦学习系统的搭建过程，包括服务端与客户端的功能实现和训练数据的处理。重点考虑了系统在多种参数配置下的适应性和灵活性，确保了模型的高效运行和良好的可扩展性。本研究提供了详尽的参数设定方法，如客户端数量、全局迭代次数、本地迭代次数及训练算法的选择等，这些设置是联邦学习系统效率和效果的关键。

（2）引入基于声誉的激励机制：引入了基于声誉的激励机制，用于提高诚实客户端的参与度并抑制恶意客户端的影响。通过综合考虑模型的准确率和损失值，设计了声誉评估的数学模型，为每个客户端计算和更新声誉值。此外，引入 Shapley 值来客观评估各客户端的贡献，并据此更新声誉值，从而提高了整个系统的数据安全性和模型准确率。

（3）进行实验验证与性能分析：通过设置不同程度的攻击环境和改变声誉调整因子，分析了激励机制在实际操作中的效果，以及在多种攻击场景下的表现。实验结果表明，该机制能有效提高联邦学习系统的鲁棒性，减少恶意攻击的影响。

1.4 论文组织结构

论文包含四个主要章节，其结构如图 1-3 所示，以下是各章节的概要：

第一章：绪论。本章主要阐述了研究的背景和重要性，对国内外在联邦学习激励机制方面的研究进展进行了梳理和分析，并介绍了本研究的核心内容和主要贡献，概述了论文的组织结构。

第二章：技术背景介绍。本章主要介绍了联邦学习的概念，并按照联邦学习训练过程中存在的子问题，总结了已提出的联邦学习激励机制，对联邦学习

框架进行了调研。

第三章：联邦学习系统模型搭建。本章主要介绍了联邦学习系统模型的搭建过程及相关配置。模型重点考虑了多种参数配置的适应性和灵活性，确保了模型的高效运行和良好的可扩展性。通过对数据集的适当处理，如图像尺寸调整和标准化，确保了数据输入的一致性和模型训练的有效性。并对联邦训练与集中式训练进行了对比分析，并探讨了不同客户端数目对模型性能的影响。

第四章：应用 Shapley 值评估的 FL 激励机制。本章的主要内容为设计使用 Shapley 值评估的联邦学习激励机制，并通过实验对系统的效率 and 安全性进行了评估。本章在已实现的 FL 系统上实现了对现有联邦学习系统的初步改进。然后引入基于 Shapley 值的声誉激励机制，进行实验对其效果进行验证。实验结果表明该方法通过精确评估客户端的边际贡献，实现了声誉值的动态调整，保障了 FL 系统的鲁棒性。




图 1-3 论文组织结构图

第2章 技术背景介绍

本章围绕本论文实现所基于的技术背景进行了介绍。本章主要分为三个部分：联邦学习的基础概念知识和现有的防御策略、激励机制及应用于联邦学习的激励机制类型、联邦学习框架概述。本章的目的是为论文的后续章节提供必要的理论基础，明确联邦学习中激励机制研究的必要性和可行性，从而为整个研究的深入展开奠定坚实的基础。

2.1 联邦学习概述

2.1.1 联邦学习的特征

联邦学习(Federated Learning)是一种设计用于加强数据安全性和隐私保护的机器学习方法。此架构通过创建数据联盟，允许各机构在不直接交换数据的情况下，共同进行学习任务，并确保所有参与方都能从中受益，促进整体技术的持续发展。

联邦学习的核心目标是解决数据孤岛问题和增强数据隐私保护。它具有以下主要特点：

- 在联邦学习的框架下，所有的参与方都享有平等的地位和身份；
- 各方的数据留在本地存储，这样既保护了参与方隐私，又符合了相关的法律规定；
- 多方参与者共同创建一个集体的共享模型，旨在实现各自的应用目标，并从中获得共同的利益；
- 联邦学习的模型效果与传统的深度学习是相似的；
- “联邦”指的是形成的数据联盟，不同的联盟具有不同的计算框架，服务于不同的业务需求。

随着联邦学习在多个领域的应用日益扩大，社会对其安全性的关注也日益增加。联邦学习相比于传统的集中式训练，虽然通过不直接交换数据提高了隐私保护水平，但它本身并不提供完全的隐私保障，仍然可能面临数据泄露的风险，因此对联邦学习中的隐私保护技术提出了更高的要求。

2.1.2 联邦学习的分类

联邦学习一般根据原始特征和标签数据的分布特性来进行分类。在构建预测模型时，特征集 X 代表输入变量，这些可以是原始特征或用户特定的特征，而标签集 Y 代表输出变量，即模型预测的结果。例如，在健康医疗领域， Y 可能指患者的疾病诊断结果；在零售领域， Y 可能表示客户的再次购买概率；在交通领域， Y 则可能指城市交通流量的预测。用户特征 X 和标签 Y 共同构成了训练数据集 (X, Y) 。

在实际应用中，不同数据集的用户特征可能存在不一致性。针对包含两个数据拥有方的情况，联邦学习可以根据用户特征的重叠程度分为以下三种类型：
(1) 横向联邦学习：适用于数据特征相似但用户群不同的情况，如图 2-1 所示。





图 2-1 横向联邦学习示意图

在横向联邦学习的框架下，经常遇到这样的情况：两个数据集在用户特征上存在较大程度的交集，但在用户身份上却很少有重合。这种现象类似于在数据管理中对数据进行横向分割。以两家分别在不同城市的连锁店为例，尽管它们吸引的顾客群体（即样本空间）可能截然不同，但它们销售的商品种类和营销策略却可能如出一辙。尽管样本空间不同，但是特征空间是共同的。因此，这两家零售连锁店能够通过横向联邦学习合作，共同训练出一个更有效的商品推荐模型。

(2) 纵向联邦学习：适用于用户群相似但数据特征不同的情况，如图 2-2 所示。

当涉及到纵向联邦学习时，通常是指多个组织共有一批用户，但是各自记录了不同的用户信息。这适用于那些虽然服务同一群体但收集了不一样属性数据的场景。比如，两个行业不同的公司可能都服务于同样的客户，但由于业务需求的差异，他们各自维护着独特的用户特征集。纵向联邦学习使得这两个公



(3) 联邦迁移学习：适用于在两种数据集之间迁移学习模型，其中一个数据集的信息有助于另一个数据集的学习过程，如图 2-3 所示。

图 2-3 联邦迁移学习示意图

联邦学习面临着一些关键挑战，随着参与设备规模增加，不同客户端的异构性日益显著，以及不断发展的攻击手段对系统的安全性构成了威胁。设计一

个联邦学习激励机制来防御恶意的参与者，对于保障联邦学习系统的稳定性和用户隐私愈发重要。

2.1.3 联邦学习的防御策略

目前研究较多的防御措施^[12]有以下几种，防御效果如图 2-4 所示：

Defenses	Attacks							
	Loss-function/Relu	First dense layer	DLG/iDLG	MIA	mGAN-AI	GAN	Adversarial example	Model poisoning
Gradient Subset	+	~	~	+	~	~	-	-
Gradient Comp	~	-	-	~	~	~	~	-
Dropout	+	-	-	+	~	+	+	~
DP	+	*	+	+	*	+	+	-
SMC	-	~	~	~	+	-	-	-

图 2-4 各类防御措施对攻击方法的有效性^[12]

(+:可靠的有效性, ~:受限的有效性, -:防御措施几乎完全无效, *:上下文相关的有效性)

梯度子集(Gradient Subset)^[13]是一种降低通信成本和隐私泄露的防御方法。它的原理是每个客户端只选择一部分梯度来上传给服务器，而不是上传所有的梯度。这样既可以降低通信量，也可以减少梯度中包含的训练数据信息。梯度子集的方法有随机采样、重要性采样、拓扑感知采样等。梯度子集可以有效地降低通信成本，适用于通信带宽受限或数据敏感性高的场景。但它会影响模型的收敛速度和精度，并会引入额外的计算开销和同步延迟。

梯度压缩(Gradient Compression)^[14]是一种通过对梯度进行压缩或量化来降低通信开销和隐私泄露的防御方法。它通过将梯度表示为更简单的形式，从而减少传输数据的大小和复杂度。梯度压缩的方法有阈值截断、稀疏表示、低秩近似、一位量化等。梯度压缩可以有效地降低通信成本和提高保护水平，同时保持模型的收敛性，一般用于通信带宽受限或数据敏感性高的场景。但是它会引入额外的计算开销和压缩误差，在实际应用中需要根据使用场景选择梯度压缩的方法和参数。

Dropout^[15]是一种通过在训练过程中随机丢弃一些神经元来提高模型鲁棒性和泛化能力的防御方法。它通过引入噪声来防止模型过拟合训练数据，从而

降低恶意攻击的成功率。Dropout 可以看作是一种正则化技术，可以有效地减少模型参数之间的共适应性。它适用于数据分布不均匀或存在噪声的场景。但是该方法会影响模型的收敛速度和稳定性，并且增加超参数的调节难度，因此实际使用中需要考虑 Dropout 的比例和位置。

差分隐私(Differential Privacy)^[16]是一种通过在数据或函数输出中添加噪声来保护个体数据隐私的防御方法。它通过降低查询结果对数据记录的敏感性，使得在给定查询结果的前提下，任何人都无法推断出个体数据是否存在数据集中。差分隐私可以应用于联邦学习中心端、客户端或两者结合，用来保护模型参数、梯度或训练数据等。其可以有效地保护个体数据隐私，并且具有完整的理论基础和数学证明^[17]，适用于数据敏感性高或存在隐私攻击的场景。它的缺点是可能会影响模型的收敛速度和精度，并且会增加噪声水平。

安全多方计算(Secure Multiparty Computing)^[18]是一种通过使用密码学协议来实现多方之间安全地计算一个函数而不泄露各自输入的防御方法，它通过将输入分割成多个片段，并在不同方之间交换加密信息来实现计算过程。安全多方计算常应用于联邦学习中心端或客户端来保护模型的聚合过程。它可以有效地保护多方数据隐私，并具有强大的安全性和可扩展性，适用于数据敏感性高或存在恶意参与者的场景。但它会增加通信开销和计算开销，并且降低模型效果和收敛速度，需要周密地设计密码学协议和优化计算过程。

2.2 激励机制

激励策略旨在通过有效的管理措施和策略，增加员工对其工作和组织的热情与承诺。这类策略主要设计用来吸引质量高的客户端积极参与到模型的训练过程中，从而实现在保持资源消耗（例如通信和计算成本）尽可能低的同时，提高模型的整体性能，包括提升模型的准确度和加速训练过程^[19]。

设 $N = \{0, 1, \dots, N-1\}$ 表示 N 个客户端，客户端 i 的成本由资源向量 $\mathbf{q}_i$ 和对应的权重向量 θ_i 表示的多维向量共同决定。当 $\mathbf{q}_i = \vec{0}$ 时表示客户端 i 未参与联邦训练。客户端 i 的利润函数表示见式（2-1）：

$$\pi_i = p_i - c_i(\mathbf{q}_i, \theta_i) \quad (2-1)$$

其中， p_i 是 N_i 从全局模型中获得的奖励， $c_i(\cdot)$ 是客户端 i 的成本函数。

服务器的利润函数表示见式（2-2）：

$$\pi = U(Q) - \sum p_i \quad (2-2)$$

其中, $U(\cdot)$ 是效用函数, Q 为 $(q_0, q_1, \dots, q_{N-1})$ 。

激励策略旨在确定参数 Q 的理想设定, 进而优化客户端与服务器之间的收益。

2.2.1 激励机制分类

激励机制一直是社会运作中不可或缺的部分, 在经济、社会和技术等众多领域都扮演着关键角色。在经济领域中, 激励机制通常通过使用金融激励手段如奖金、折扣或市场定价策略, 来激发个体或企业的参与意愿。在社会领域上, 激励一般包括声誉系统、排名或社会认可, 通过社会心理影响来促进合作和贡献。在技术领域则关注于通过技术进步来降低参与门槛, 提高效率, 比如使用自动化工具和用户友好的接口来减轻用户的参与负担, 从而提供激励。

激励机制被分为以下几个主要类别。直接金融激励一般通过现金奖励和代币, 直接奖励参与者的贡献。间接金融激励则可能包括税收优惠、补贴或其他财政措施这些通常用于鼓励长期投资或支持研究和发展活动。非金融激励一般涉及访问特定资源的机会, 或者提供可以增强个人能力或者组织名誉的机会。

激励机制还必须考虑到可持续性和公平性问题。比如在环境可持续性项目中, 激励机制的设计就旨在鼓励减少碳排放, 或者减少资源的浪费。公平性原则要求激励机制在鼓励特定行为的同时不会无意中排斥某些群体或者加剧现有的不平等情况。

2.2.2 联邦学习激励机制

在联邦学习领域, 激励机制是一种创新的防御策略。设计激励机制时, 关键因素包括客户端的数据贡献、资源使用、隐私保障和声誉评价, 目的是为了确保持系统的公平性^[20]、效率和安全性^[21]。

在典型的联邦学习场景中, 激励机制使得服务器能够基于客户端的成本效益和贡献度来选择参与训练的客户端。初始阶段, 服务器筛选出适合的客户端进行首轮训练, 训练完成后, 根据各客户端的贡献大小进行奖励分配。在下一训练轮次前, 客户端根据收益调整资源配置。客户端随时可选择加入、退出或持续参与联邦学习。初次加入者由服务器分配初始参数, 而退出者将受到服务器的适当惩罚。参与者通过调整资源策略进行多轮博弈, 直至系统平衡^[19]。

联邦学习激励机制主要涵盖三个子问题: 贡献度量、客户选择和支付分配,

如图 2-5 所示。下面将从贡献度量、客户选择、支付分配这三个方面讨论现行的联邦学习激励机制方案。




图 2-5 联邦学习激励机制的子问题

在贡献度量的激励机制里，为了评估与奖励参与者所提供的计算与通信资源，必须建立一套贡献度评估系统。此系统确保参与者在获得适当的补偿之前不会加入到项目中。有效的评估标准不仅提升联邦系统的总体性能，还能吸引更多优质用户参与。这些激励策略通常按贡献的类型分为单一维度和多维度的度量方法。




图 2-6 基于声誉的客户选择

客户选择是联邦学习中的关键环节，旨在选取合适的参与方以最大化系统效用。采用激励策略能有效提高系统整体表现，并且有助于降低训练过程中的工作量和资源开销。因此，将激励机制应用于选择客户的过程是一个极具潜力的研究领域。在基于声誉的激励系统中，客户的声誉分数能够间接反映其可信

度及数据的质量，声誉高的客户更有可能对训练任务作出质量较高的贡献。正如图 2-6 展示的，每个任务周期完成后，服务器会根据客户的表现更新其声誉评级。高声誉的用户将被优先考虑参与下一次迭代。

支付分配是基于参与者贡献的评估来确定各客户端的奖励类型和数量。这一策略确保按照参与者提供的资源和数据质量来调整其收益，从而保证系统激励的公平性和效率。通过实施公平的支付分配，可以有效增强参与方的积极性，维护学习网络的动态稳定。奖励的具体计算可依据经济理论，如拍卖理论、博弈论和 Shapley 值分析，来精确地反映每个参与者的实际价值，从而促使高质量的用户留在联邦学习中。

2.3 联邦学习框架

目前的市场上已经存在多个成熟的联邦学习框架。FATE^[22]（Federated AI Technology Enabler）是一个联邦学习框架，由微众银行于 2019 年公开发布。该平台的设计理念是在数据隐私保护的前提下，允许不同机构之间合作解决机器学习问题，而不需要直接交换数据。

FATE 实现了一系列的安全计算协议，这些协议基于先进的同态加密和多方安全计算（MPC）技术，确保了在参与方之间的计算过程中数据的隐私性和安全性不被破坏。

该框架支持多种机器学习算法，适用于各类模型，诸如线性模型、树模型（如梯度提升决策树 GBDT）和神经网络模型（如卷积神经网络 CNN）等。这使得 FATE 能够应用于横向联邦学习、纵向联邦学习以及迁移学习等多种联邦学习场景。

除了基础的机器学习算法支持，FATE 还提供了一套完整的联邦学习模型服务，比如特征工程、模型评估、在线推理服务和样本安全匹配等。这些服务旨在帮助用户更容易地构建、评估和部署联邦学习模型。

FATE 的开发流程通常包括数据的联邦统计分析、特征工程处理、模型的训练与优化，以及模型的部署与推理。整个流程充分考虑了数据安全和隐私保护的需求，底层的多方安全计算协议为上层的机器学习算法和模型训练提供了坚实的安全基础。因此，FATE 成为了在注重数据隐私保护的联邦学习领域的一个重要工具。

FATE 框架的优势在于其成熟的架构、全面的组件和在计算、通信和存储层面提供的抽象层，方便用户根据需求进行定制。但是 FATE 也存在一些缺点，

比如它的框架庞大导致部署过程繁琐、内存需求高，并且在边缘计算场景中处理新加入客户端的能力不足等。FATE 的技术架构图如图 2-7 所示。




图 2-7 FATE 的技术架构

鉴于现有联邦学习系统已经较为成熟，难以在其基础上进行改动，因此本论文使用 Python 编程语言实现了一套基于联邦平均算法的联邦学习框架，并在此基础上进行激励机制的模拟和实验验证。

2.4 本章小结

本章总结了联邦学习的关键技术背景，包括其主要特征与分类、防御策略、联邦学习中的激励机制以及现有联邦学习框架。联邦学习的特征突出了数据隐私保护和分布式计算的重要性。在分类方面详细讨论了横向联邦学习、纵向联邦学习和迁移联邦学习的应用场景和数据特性。防御策略部分介绍了联邦学习中常用的防御方法。激励机制则关注于在联邦学习的各个环节中进行激励。联邦学习框架则对现有技术进行了总结。这些理论和技术的详细介绍为联邦学习系统模型的搭建和基于 Shapley 值的声誉激励机制的效果验证提供了前提。

第3章 联邦学习系统模型搭建

本章详细介绍了联邦学习系统模型的搭建过程及相关配置，服务端与客户端的功能实现和训练数据的处理。本研究在构建联邦学习系统时，重点考虑了多种参数配置的适应性和灵活性，确保了模型的高效运行和良好的可扩展性。在实验部分，本研究对联邦训练与集中式训练进行了对比分析，并探讨了不同客户端数目对模型性能的影响。通过这些实验，旨在展示联邦学习在处理分布式数据时的优势，以及在保护用户隐私方面的潜力。

3.1 联邦学习系统的构建

3.1.1 配置信息

联邦学习的开发阶段需要对多个关键参数进行配置，本论文使用了以下的配置项：

参与训练的客户端数量：在联邦学习的每轮迭代过程中，服务端将从所有可用的客户端中选取一定数量的客户端来进行本地模型的训练。这种做法不会影响模型最终达到的全局收敛状态，同时能够显著提高训练的效率。通过这种方式，可以在不牺牲模型性能的前提下，减少必要的计算资源和时间，使得训练过程更加高效。

全局迭代次数：该参数决定了服务端和客户端进行交互的整体轮次总数，训练过程可在模型达到收敛条件时提前结束。

本地模型迭代次数：指各客户端在执行本地训练时的迭代轮数。本论文为所有客户端进行了统一设置。

针对本地模型训练的算法参数配置：涉及在各客户端上训练模型时所采用的参数设定，比如学习率（lr）、选定的训练数据集规模、所选用的优化算法等因素。

模型信息：即使用的模型结构。本论文选择使用 LeNet-5 图像分类模型。

数据配置：本论文使用的是 MNIST 数据集进行联邦学习训练。为实现横向联邦学习，将数据集依据样本维度分割成多个互不重叠的子集，每个子集分配给不同的客户端用于本地训练。

3.1.2 训练数据集

本系统根据配置文件中的相应字段获取所需要的数据集。本论文使用 MNIST 数据集。由于 LeNet-5 网络设计时预设的输入图像尺寸为 32×32 像素，而 MNIST 数据集中的图像原始尺寸为 28×28 像素且为灰度单通道，因此需要对这些图像进行尺寸调整以匹配网络输入。这一调整通过图像转换操作 `transforms.Resize` 实现，将每张图像的尺寸从 28×28 扩展到 32×32 。然后图像被转换成 Tensor 格式，这是深度学习模型所需的数据类型。为了提高模型训练的效率 and 收敛速度，执行标准化处理：图像的每个像素值减去整个数据集的像素均值，然后除以标准差，确保转换后的数据集具有均值为 0 和方差为 1 的分布特性，这有助于梯度下降过程中更平稳快速地找到最优解。

这里 MNIST 数据集的标准化为 `transforms.Normalize((0.1307,), (0.3081,))`。

3.1.3 服务端

在横向联邦学习中，服务端的核心任务是进行模型聚合。它汇总所有选定客户端上传的本地模型数据，合并这些数据以更新全局模型。本模拟假设在理想环境中运行，不包括网络通信故障或其他相关故障的处理，因此主要关注模型聚合的功能实现。

创建一个服务端类，其中包括三个核心方法：

首先是构造方法。在此方法中，服务端首先将配置信息导入，然后根据这些配置信息加载指定的模型，本例中采用的是 LeNet-5 模型进行训练。

接下来是模型聚合方法的定义。服务端的一项关键职责是整合各客户端提交的模型更新。因此，该类需要包含一个处理模型聚合的方法，它将接收来自客户端的模型参数，并应用 FedAvg 算法来更新全局模型。FedAvg 算法，其基本公式如下：

$$G^{t+1} = G^t + \lambda \sum_{i=1}^m (L_i^{t+1} - G_i^t) \quad (3-1)$$

其中， G^t 表示第 t 轮聚合完毕时的全局模型， L_i^{t+1} 表示第 i 个客户端在完成第 $t+1$ 轮本地更新之后的模型状态， G^{t+1} 表示第 $t+1$ 轮聚合之后的全局模型。

最后，定义模型评估方法。这个方法旨在评估经过聚合的全局模型的性能，通过对全局模型的性能进行评估来判断模型是否出现了退化现象，帮助决定是否继续进行更多的训练迭代或者提前终止训练。根据评估结果，服务端可以采

取相应的措施来优化训练过程。

通过这些方法，服务端能够有效地管理和指导联邦学习过程中的模型训练和评估。

3.1.4 客户端

在横向联邦学习场景中，客户端的主要任务是接收服务端发送的全局模型和相关指令，并使用其持有的本地数据集进行局部模型的训练。以下详述了客户端类“Client”的核心功能及其构造方法：

首先是构造方法的定义。在此方法中，客户端首先将从服务端接收的配置信息复制到本地环境中，然后根据这些配置信息加载相应的模型。服务端会向客户端发送模型的参数，客户端使用这些参数来初始化或更新其本地模型。此外，客户端还需要配置其本地训练数据，通过利用“torchvision”库中的“datasets”模块，可以有效地下载 MNIST 数据集并根据客户端 ID 对数据进行分配，从而确保各客户端获取的子数据集彼此之间不会有交集。

接着是本地模型训练方法的定义。考虑到所处理的是一个图像分类问题，客户端使用交叉熵作为损失函数，并采用梯度下降法来更新模型参数。这种方法有助于优化模型性能，通过逐步调整参数以减少预测误差。

3.1.5 整合

在具体运行中，系统会读取配置文件中的信息以获取必要的参数，例如模型信息、数据分割方式和客户端数量等。根据配置信息，首先初始化一个服务端对象以及多个客户端对象，这些对象代表着参与训练过程的不同参与者。在联邦学习的每一轮迭代中，服务端扮演关键角色，它从所有客户端中随机选择一部分进行本轮的训练。这样的选择模拟了现实世界中的情形，其中只有部分设备可能处于在线状态或愿意参与到训练过程中。

被选中的客户端则利用其本地数据执行名为“local_train”的方法，执行模型训练过程，并对本地的模型参数进行更新。此过程涉及数据的前向传播、损失计算、反向传播以及参数的梯度下降更新。

完成训练后，各客户端会将其更新后的模型参数上传至服务端。服务端接着通过执行名为“model_aggregate”的方法，对所有参与当前轮训练的客户端上传的模型参数进行聚合，从而更新全局模型。服务端模型聚合完成后，调用

“model_eval”方法对更新后的全局模型进行性能评估，以确定当前模型是否达到预期的学习效果，或是否需要进行进一步的迭代。

3.2 联邦训练的模型效果

3.2.1 联邦训练与集中式训练的效果对比

为了对比联邦训练和集中式训练的效果，本文设定了两种不同的训练配置。

在联邦训练配置中，设定了 10 个客户端，每轮训练中有 5 个客户端参与，每个客户端在本地进行 3 次迭代训练，而全局模型则进行 20 次迭代更新。这样的设置旨在模拟一个分布式的训练环境，其中多个客户端共同协作，但每轮训练只有一部分客户端参与到模型的更新中。

对于集中式训练配置，将客户端数量和每轮参与训练的客户端数量都设置为 1，本地迭代次数也调整为 1 次，其余的参数配置与联邦训练相同。这种配置实际上是将联邦学习简化为单机训练模式，所有训练数据集中在一台设备上，不涉及数据的多节点协同处理。

图 3-1 展示了这两种训练方式的效果对比。结果显示，虽然训练的配置不同，但联邦学习的训练效果与集中式训练在性能上基本持平。这表明在某些情况下，联邦学习能够在有效地处理数据的同时维护数据隐私和安全。




图 3-1 两种训练方式迭代后的效果对比

3.2.2 联邦模型与单点训练模型的对比

为了比较模型在推断阶段的性能，实验设计了两种不同的训练策略：单点训练模型和联邦训练模型。单点训练模型仅在单一客户端上训练，利用该客户端的本地数据进行训练。联邦训练涉及多个客户端在训练过程中协作，共同更新一个全局模型。本实验设计中设置了两种不同的客户端参与度($k=3$ 和 $k=6$)

实验中随机选择了五个客户端进行评估以了解其在两种训练方式下的模型表现。




图 3-2 联邦训练模型与单点训练模型性能比较

在图 3-2 中可以看到联邦训练的模型效果明显优于单点训练的模型效果。单点训练模型仅依赖单一客户端的数据进行训练，所以无法充分捕捉到数据的全局分布特征，导致模型的泛化能力较弱。联邦训练通过多个客户端的协作，使得模型能够接触到更广泛的数据分布，从而提高了模型的泛化能力。并且随着参与每一轮训练的客户端数的增加，模型的性能相应提高。因为更多客户端的参与增加了数据的多样性，有助于模型学习到更加全面的特征。

增加 k 值虽然能提升模型性能，但是也会导致每一轮训练的完成时间延长。更多的客户端参与意味着需要更多的计算资源和时间来完成数据的上传、模型的更新和同步等操作。

3.3 本章小结

在配置信息方面，本文提供了详尽的参数设定方法，比如客户端数量、全

局迭代次数、本地迭代次数以及训练算法的选择等关键参数，通过这些精心设计的配置，为联邦学习系统提供了足够的灵活性，以适应不同的运行环境和需求。本研究使用 LeNet-5 模型和 MNIST 数据集作为训练的基础，以验证所建系统的性能。通过对数据集的适当处理，进行图像尺寸调整和标准化，确保了数据输入的一致性，从而提高模型训练的有效性。

第4章 应用 Shapley 值激励的 FL 防御方法

本章围绕使用 Shapley 值评估的联邦学习激励机制进行了深入探讨和实验验证。通过一系列的设计和实验设置，对基于激励机制的 FL 系统的效率 and 安全性进行了评估。该机制通过对每个参与者的边际贡献进行定量的评估，从而精确地计算出其对整体学习过程的影响。联邦学习系统通过实施这一声誉激励机制，能够更有效地管理和激励参与者，确保所有客户端均按照其真实的贡献获得相应的声誉评分。

4.1 基于现有联邦学习系统的初步改进

面向实际的使用场景，联邦学习的参与者不仅仅有诚实友好的客户端，也会出现恶意的客户端参与训练，它们可能会采用各种各样的攻击来窃取用户数据或污染聚合模型，因此需要在现有模型基础上实现恶意客户端的模拟以及采用激励机制进行防御。

4.1.1 增加预训练环节

考虑到在现已实现的联邦学习系统上引进激励机制，需要在每轮迭代训练中引入一个参照值进行比对才能够确定哪些是正常客户端，哪些是恶意客户端。由于服务端在进行模型聚合时，无法确定客户端的好坏，如果仅仅根据该轮参与训练客户端的平均数据进行判断，也可能出现恶意客户端被误判为诚实客户端的情况，因此本论文选择在正式的全局迭代训练前选择一个诚实客户端进行单个客户端的模拟训练，这在现实的使用场景下是完全可能并可行的，训练方可以事先确定一个正常的数据提供者训练的模型作为联邦学习训练模型的性能参考。

4.1.2 模拟恶意客户端的攻击

本论文采用对抗性攻击与标签注入攻击的方式实现恶意客户端的攻击功能。对抗性攻击的目标是通过修改输入数据，使得模型在预测上产生错误。本文通过使用 PyTorch 的 torchattacks 库中的 FGSM (Fast Gradient Sign Method) 攻击

来对输入数据进行扰动，攻击者可以使用生成的对抗性样本来训练模型，从而降低模型的准确率。

标签注入攻击通过控制"attack_probability"参数来控制进行恶意攻击的概率，即在每个批次的数据中，以一定的概率"attack_probability"将正确标签修改为随机选择的错误标签。这个过程模拟了联邦学习的恶意参与者故意使一部分训练数据标签出现错误的情况。标签注入攻击会导致训练模型的损失率有较大的提高。

为了更灵活地控制每种攻击类型的客户端数量，在 conf.json 文件中添加了两两种攻击方式客户端数量的配置项，在实际运行中根据这些配置来动态地设置客户端的攻击类型与数量。综合以上两种攻击方式可以较为全面的模拟联邦学习恶意参与者的攻击。

4.1.3 引入声誉评估机制

根据已实现的联邦学习系统中参数服务器和客户端之间互动和决策的描述，本论文采用了声誉的方式进行激励。本系统的声誉激励机制与现有机制的主要区别在于，将客户端的声誉直接与全局模型的聚合挂钩，从而确保了参与者的积极性和模型的质量。

为了保证客户端与服务器之间的通信安全，在服务端维护了一个声誉列表存储每个客户端所对应的声誉值，客户端在本地训练时无法得知自己的声誉。这种设置防止了客户端直接访问并操纵自己的声誉值，从而有效避免了潜在的声誉攻击。

具体的声誉计算逻辑是构造了一个综合准确率和损失值的函数表达式如下：


$$\Gamma_k = \alpha \times (acc_k + \frac{1}{loss_k}) + \beta \quad (4-1)$$

其中表达式中的 Γ_k 为动态阈值， acc_k 和 $loss_k$ 为正常模型第 k 轮的准确率和损失值， α 和 β 为参数因子。正常模型每轮的准确率和损失值可以通过预训练正常客户端可以得到，其数据保存在服务端作为标准值。


在训练过程中，服务端为所有客户端在训练伊始赋予一个初始声誉值，每轮迭代后先根据各客户端当前声誉值占该轮次所有参与训练的客户端声誉值之和的比例进行模型聚合，声誉值占比更高的客户端模型聚合模型比例也就更高。全局模型聚合完毕后，各客户端进行模型评估所得到的准确率和损失值，计算其综合函数的值并与标准综合函数进行比较，若大于该阈值，则其声誉增加，

反之减少。最后再对客户端声誉值进行截断，确保其处在合理范围内。

4.1.4 使用激励机制的 FL 训练与普通 FL 训练对比



(a) 准确率对比



(b) 损失值对比

图 4-1 两种机制的效果对比

根据图 4-1(a)的准确率对比图，使用激励机制的联邦学习方法在迭代训练中

表现好于普通联邦平均方法。随着迭代次数的增加，使用激励机制的联邦学习方法的准确率逐渐提高，普通联邦平均方法的准确率也在增长但增长速度较慢。根据图 4-1(b)的损失值对比图，使用激励机制的 FL 方法的损失值相对较低，表现更为优秀。随着迭代次数增加，两种方法的损失值均呈下降趋势，但使用激励机制的 FL 方法的损失值下降速度更快，收敛更迅速。综合来看，使用激励机制的 FL 方法在准确率和损失值方面表现均优于普通联邦平均方法。

4.2 基于 Shapley 值的声誉更新机制

在联邦学习系统中，有效地评估和更新客户端的声誉值是确保数据质量和激励参与的关键。为了更精准地反映客户端的实际贡献和行为，本论文提出了一种基于 Shapley 值的声誉更新机制。这种方法不仅考虑了客户端的贡献大小，并且细化了声誉值的调整过程。

4.2.1 使用 Shapley 值评估贡献

在联邦学习系统中，公正透明地评估每个参与者的贡献是非常重要的，本论文采用了 Shapley 值来量化每个客户端在共享模型中的贡献。Shapley 值是由 L.S.Shapley 提出的数学方法，主要用于在合作游戏理论中将合作行为产生的总收益公平地分配给各个合作方。其核心理念是评估一个参与者加入已存在的合作组合时所带来的边际改变。

数学上，Shapley 值的定义是基于所有可能的参与者组合，量化单个参与者带来的额外价值。具体公式见式（4-2）：

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} (v(S \cup \{i\}) - v(S)) \quad (4-2)$$

其中， N 是所有参与者的集合， i 是被评估的参与者， S 是不包括参与者 i 的任何子集，而 $v(S)$ 是子集 S 的价值。这个价值通常由某个性能指标(如模型的准确率或损失函数)来衡量，而 $v(S \cup \{i\})$ 表示当参与者 i 加入子集 S 后的新价值。

在具体实现过程中，先将每个客户端初始化其 Shapley 值为零，并计算客户端总数的阶乘以方便后续计算中使用。然后对每个客户端进行迭代，计算其与各种可能的客户端子集组合的价值差异。对于每个客户端，通过排除该客户端并考虑所有其他客户端的所有可能组合来模拟不同的合作场景。这里需要计算

两种情况下的模型性能：一种是当前客户端参与时的情况，另一种是当前客户端不参与时的情况。每次计算模型性能时，先重置全局模型到初始状态，再将每个客户端的本地更新累积到全局模型上，然后通过预设的评估函数评估模型性能。

这两种情况下的性能差异反映了包含当前客户端与不包含当前客户端的价值差异，即该客户端的边际贡献。根据这个边际贡献和所有可能的客户端子集的组合计数，按照数学公式计算更新该客户端的 Shapley 值。这样通过综合所有可能的合作配置得到了每个客户端的平均贡献值。

该方法能够量化每个客户端的具体贡献，并且在系统中实现了更公正的激励和资源分配。基于 Shapley 值的贡献评估机制为联邦学习系统中的合作公平性提供了数学基础和实施方法。

4.2.2 优化 Shapley 值的计算过程

对于每个客户端，代码都会遍历除该客户端外的所有其他客户端组合来计算 Shapley 值。这种方法在客户端数量较少时是可行的，但是因为组合的数量增长是指数级的，随着客户端数量的增加计算成本会急剧上升。

在优化 Shapley 值计算过程中，本论文采用了备忘录技术以提高计算效率并避免重复计算相同的模型评估。在本论文的实现中，备忘录用于记录不同客户端子集对模型性能的影响。对于每个客户端的 Shapley 值计算，需要评估包含该客户端与不包含该客户端的各种客户端组合对模型性能的影响。备忘录为每个客户端子集创建了一个唯一的键，并将该子集的模型评估结果存储在备忘录中。每当需要评估相同的客户端子集时，可以直接从备忘录中检索结果，无需重新进行模型评估，从而达到了性能优化的效果。

4.2.3 细化声誉值的调整过程

本论文通过以下几种方式，对声誉值的调整过程进行了细化：

（1）分位数阈值：

本论文设定了分位数阈值（低分位数和高分位数），并将客户端分为三组：高贡献、中等贡献和低贡献。只有当客户端的 Shapley 值低于低分位数或高于高分位数时，其声誉值才会受到显著的调整。这种分位数阈值方法有助于区分客户端的贡献水平，从而进行更合理的声誉值更新。

（2）非线性调整策略：

考虑到存在着极端表现的客户端，无论是表现优异的还是表现不佳的，其声誉值的变化应当更为敏感。因此本论文采用了非线性的调整策略，即使用 sigmoid 函数，该函数因为其 S 形曲线特性，适用于处理需要平滑过渡的调整场景。如果客户端的 Shapley 值超出高分位数，则计算其与该分位数之间的偏差，并将此偏差值代入 sigmoid 函数进行处理。为使调整值能够围绕零点上下浮动，从函数输出的处理结果中减去 0.5，实现声誉值的正向或负向调整。类似如果 Shapley 值低于低分位数，同样计算偏差并通过调整函数进行相应的负向调整。这种方法不仅确保了声誉值更新的敏感性，还避免了声誉值的单向增长或减少，有助于维持系统内各客户端声誉的动态平衡。这种基于客户端表现的细粒度调整策略，提高了联邦学习系统整体的效率和公平性，确保了高质量数据的贡献从而提升了模型训练的有效性。

（3）比例调整：

传统的声誉值更新通常采用固定量的增减，可能无法准确反映客户端的贡献变化。因此本论文采用了一种基于归一化偏差的比例调整方法。此方法不仅考虑客户端的 Shapley 值，而且依据其相对于预设分位数阈值的位置进行调整。通过计算每个客户端的 Shapley 值相对于特定分位数阈值（低分位数和高分位数）的偏差。这种偏差通过将 Shapley 值与分位数之间的差值除以分位数范围的极差（即最大值与高分位数之间的差或低分位数与最小值之间的差）进行归一化。这样的归一化处理确保了偏差的计算不受原始数据规模的影响，从而使调整过程更为公正和适度。


4.3 实验结果

4.3.1 相同调整因子下不同攻击程度的防御效果对比


本节中，主要关注在固定声誉调整因子为 5 的条件下，恶意客户端不同的攻击强度对模型防御效果的影响。通过系统地调整对抗性攻击和标签注入攻击的参数，设置了三种测试环境：无攻击(攻击概率设置为 0)、弱攻击(攻击概率设置为 0.5)和强攻击(攻击概率设置为 1)，以评估所设计的激励机制在应对不同程度攻击时的有效性。

通过对比有攻击环境 and 无攻击环境，如图 4-2 所示，可以发现在攻击环境

下，模型通过激励机制成功适应了攻击，最终使得模型的准确率和损失值均接近无攻击环境下的模型训练结果。值得注意的是，在强攻击环境下，模型虽然遭受了较大的初始攻击，但凭借激励机制的帮助，模型恢复速度更快，其性能在迭代结束时甚至较于无攻击环境的模型性能有所提升。



(a) 准确率对比




(b) 损失值对比

图 4-2 不同攻击环境下的效果对比


实验结果发现即便在强攻击条件下，所涉及的激励机制使模型不仅能维持基本的功能，还能通过持续学习和适应，反向利用攻击来提升其性能。模型在强攻击环境下表现更为优秀，下面将在强攻击环境下通过修改调整因子的数值来观察防御效果的变化。

4.3.2 相同攻击程度下不同调整因子的防御效果对比

在本节中，对比分析了在相同攻击条件下，不同声誉调整因子对模型性能的影响。结合上节结论，在强攻击行为背景下进行该实验，即固定对抗性攻击和标签注入攻击的概率参数为 1。实验目的在于探讨声誉调整因子取值为 0、3、5、7 时的模型表现。实验结果如图 4-3 所示。



(a) 准确率对比



(b) 损失值对比

图 4-3 不同调整因子下的效果对比

当声誉调整因子为 0 时，模型的准确率从 18.66% 增长到 88.42%，损失值从 2.29 下降到 1.46。这表明在无调整因子的情况下，模型在初期表现较差，但随着训练的深入，性能逐渐改善。

在调整因子为 3 时，模型的准确率表现稍优，从 23.72% 增长到 90.32%，损失值也更低，从 2.29 降至 1.18。说明适度增加调整因子可以有效提升模型的抵抗攻击能力和学习效率。

当调整因子设为 5 时，模型准确率的增长表现最佳，从 15.70% 增长到 91.25%，损失值从 2.29 降到 1.01。尽管起始准确率较低，模型的最终性能却是四种情况中最好的。

最后，调整因子为 7 的情况下，模型起始于 20.63%，终值达到 91.36%，损失值从 2.28 降至 0.96，模型性能好。

比较调整因子为 5 和 7 时的模型表现，发现尽管两者最终准确率相近，但在整体训练过程和损失值下降速度上，调整因子为 5 的设置显示出更佳的效果。


从模型准确率和损失值的变化来看，调整因子为 5 的模型在训练早期阶段就迅速改善了损失值，这表明模型较快地适应了训练数据，并有效抵抗了攻击。而调整因子为 7 的模型虽然最终损失值较低，但其损失值的降低并不如调整因子为 5 时的快速和平稳。说明尽管高调整因子能够进一步提高模型的稳定性，但它在训练初期可能不够有效，需要更长的时间来适应攻击和数据。

虽然两个模型最终的准确率非常接近，但调整因子为 5 的模型在中期阶段已经接近于其最终性能，表现出了更快的性能提升。相比之下，调整因子为 7 的模型在整个训练过程中改进较为缓慢，表明其在适应性和效率方面可能不如调整因子为 5 时的表现。因此，虽然调整因子为 7 最终达到了类似的高准确率，但考虑到训练效率和模型的快速适应性，调整因子为 5 提供了更均衡的性能改进。综上所述，增加声誉调整因子有助于提高模型在对抗性环境下的鲁棒性。


4.3.3 客户端的 Shapley 值和声誉值变化

根据 4.3.2 节的效果对比，本节关注于在强攻击环境下，声誉调整因子设为 5 时，客户端的 Shapley 值和声誉值的变化情况。训练伊始，所有客户端的初始声誉均设为 6.0，声誉的变化范围设定在 0.1 至 10 之间。本实验目的在于评估所设计的基于 Shapley 值的声誉激励机制在不同客户端行为下的响应及其对系统整体稳定性的影响。

如图 4-4(a) 所示，正常客户端的 Shapley 值普遍表现出正增长趋势，与其声誉值增长相匹配，反映出系统能够准确识别并奖励正常行为，增强了模型的信任度和协作质量。特别是在强攻击环境中，声誉系统不仅保持了正常客户端的活跃和贡献，还通过持续提升其声誉值，激励了持续和稳定的正向贡献。



(a) Shapley 值变化



(b) 声誉值变化

图 4-4 客户端的 Shapley 值和声誉值变化

对于表现出恶意行为的客户端，如对抗性攻击和标签注入攻击的客户端，观察到其 Shapley 值明显下降，最终趋向于零或负值。相应地，如图 4-4(b)所示，这些客户端的声誉值也显著下降，最终稳定在最低限度。这一变化说明声誉系统能有效地辨别并抑制恶意行为，通过降低这些客户端的声誉，减少了它们对系统整体性能的负面影响。

综合来看，基于 Shapley 值的声誉激励机制的引入显著增强了模型在对抗性环境中的鲁棒性。通过动态调整客户端的声誉值，系统不仅能奖励有益行为，还能有效地限制和减轻恶意行为的影响。

4.4 本章小结

本章通过增加预训练环节和模拟恶意客户端的攻击，实现了对现有联邦学习系统的初步改进。这些改进不仅加强了系统对恶意行为的防御能力，还提高了整体模型的数据安全性和可靠性。引入的基于 Shapley 值的声誉评估机制有效地区分了诚实与恶意客户端，为模型聚合提供了一个更为精确的权重基准。在实验部分详细比较了在不同攻击程度下，相同声誉调整因子的防御效果，并探讨了不同声誉调整因子在相同攻击背景下的性能差异。结果表明适当的声誉调整因子可以显著提高模型在对抗性环境中的表现，尤其是在强攻击环境下适当的声誉调整因子不仅有助于模型快速恢复，还能进一步提升其性能，表现出了激励机制在实际应用中的效果。

结 论

本文深入研究了联邦学习系统的搭建和基于 Shapley 值的声誉激励机制的应用。本文详细介绍了联邦学习的技术背景并对现有的激励机制进行了全面的评述，构建了一个高效且可扩展的联邦学习系统模型，通过实际数据集的处理和模型训练验证了模型的有效性。本文在联邦学习系统模型上实现了对客户端 Shapley 值的计算方法，准确评估了联邦学习各个参与者的贡献，据此设计了一种新型的声誉激励机制。通过对比实验，本文展示了该激励机制在提高系统鲁棒性和数据安全性方面的优势。

本论文的主要工作总结如下：

（1）联邦学习系统模型的构建与优化：建立了一个全面的联邦学习系统模型，考虑了多种参数配置的适应性和灵活性，确保了模型在多客户端环境下的高效运行和良好的可扩展性。通过使用 LeNet-5 模型和 MNIST 数据集进行训练，有效地证明了模型配置的合理性，并且通过实验验证了该模型的有效性。

（2）基于 Shapley 值的联邦学习激励机制设计与实验验证：引入了基于 Shapley 值的声誉激励机制，为联邦学习环境中如何公正地评估各参与者的贡献提供了一种新的方法论。通过设计的激励机制，不仅增强了系统的数据安全性和防御恶意攻击的能力，还通过实验验证了其在实际应用中提高系统鲁棒性的效果。

尽管本文所述的基于 Shapley 值的联邦学习激励机制已经取得了一定的成果，但仍然存在一些问题和挑战。例如，本文使用的模型评估指标较少，可以考虑引入更多的评估指标，以更全面的评估模型性能和对客户端进行更好的筛选。未来的研究可以引入更加多样化的模型架构和训练策略来进一步提升模型的适应性和效能，探索不同类型的神经网络模型和优化算法以适应更加复杂的应用场景。此外，如何将激励机制应用到更大规模的实际网络中，也是一个值得深入研究的课题。

参考文献

- [1] Li S, Cheng Y, Liu Y, et al. Abnormal client behavior detection in federated learning[J]. arXiv preprint arXiv:1910.09933, 2019
- [2] Enthoven D, Al-Ars Z. An Overview of Federated Deep Learning Privacy Attacks and Defensive Strategies[J]. Federated Learning Systems: Towards Next-Generation AI, 2021: 173-196.
- [3] 王浩竣,梁亚楠,黎琳,等. 联邦学习隐私保护机制综述[J]. 现代计算机,2022,28(14):1-12. DOI:10.3969/j.issn.1007-1423.2022.14.001.
- [4] McMahan H B, Moore E, Ramage D, et al. Federated learning of deep networks using model averaging[J]. arXiv preprint arXiv:1602.05629, 2016, 2: 2.
- [5] Lyu, Lingjuan, Han Yu, and Qiang Yang. "Threats to federated learning: A survey." arXiv preprint arXiv:2003.02133 (2020).
- [6] Li, Suyi, et al. "Learning to detect malicious clients for robust federated learning." arXiv preprint arXiv:2002.00211 (2020).
- [7] JIAWEN KANG, ZEHUI XIONG, DUSIT NIYATO, et al. Incentive Design for Efficient Federated Learning in Mobile Networks: A Contract Theory Approach[C]. //2019 IEEE VTS Asia Pacific Wireless Communications Symposium: IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS), 28-30 Aug. 2019, Singapore, Singapore.:Institute of Electrical and Electronics Engineers, 2019:1-5.
- [8] TIANSHU SONG, YONGXIN TONG, SHUYUE WEI. Profit Allocation for Federated Learning[C]. //2019 IEEE International Conference on Big Data: Big Data 2019, Los Angeles, California, USA, 9-12 December 2019, [v. 4].:Institute of Electrical and Electronics Engineers, 2019:2577-2586.
- [9] Jingwen Zhang, Yuezhou Wu, and Rong Pan. 2021. Incentive Mechanism for Horizontal Federated Learning Based on Reputation and Reverse Auction. In Proceedings of the Web Conference 2021 (WWW '21). Association for Computing Machinery, New York, NY, USA, 947 – 956. <https://doi.org/10.1145/3442381.3449888>
- [10] Zhan Y, Li P, Qu Z, et al. A learning-based incentive mechanism for federated learning[J]. IEEE Internet of Things Journal, 2020, 7(7): 6360-6368.
- [11] Hu R, Gong Y. Trading data for learning: Incentive mechanism for on-device federated learning[C]//GLOBECOM 2020-2020 IEEE Global Communi

- cations Conference. IEEE, 2020: 1-6.
- [12]陈明鑫,张钧波,李天瑞. 联邦学习攻防研究综述[J]. 计算机科学,2022,49(7): 310-323. DOI:10.11896/jsjcx.211000079.
- [13]McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.
- [14]Lin Y, Han S, Mao H, et al. Deep gradient compression: Reducing the communication bandwidth for distributed training[J]. arXiv preprint arXiv:1712.01887, 2017.
- [15]Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
- [16]Dwork C, McSherry F, Nissim K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of Cryptography: Third Theory of Cryptography Conference, TCC 2006, New York, NY, USA, March 4-7, 2006. Proceedings 3. Springer Berlin Heidelberg, 2006: 265-284.
- [17]Triastcyn, Aleksei, and Boi Faltings. "Federated learning with bayesian differential privacy." 2019 IEEE International Conference on Big Data (Big Data). IEEE, 2019.
- [18]Goldreich O, Micali S, Wigderson A. How to play any mental game, or a completeness theorem for protocols with honest majority[M]//Providing Sound Foundations for Cryptography: On the Work of Shafi Goldwasser and Silvio Micali. 2019: 307-328.
- [19]梁文雅,刘波,林伟伟,等. 联邦学习激励机制研究综述[J]. 计算机科学, 2022, 49(12):46-52. DOI:10.11896/jsjcx.220500272.
- [20]Li, Tian, et al. "Fair resource allocation in federated learning." arXiv preprint arXiv:1905.10497 (2019).
- [21]Zhan Y, Zhang J, Hong Z, et al. A survey of incentive mechanism design for federated learning[J]. IEEE Transactions on Emerging Topics in Computing, 2021, 10(2): 1035-1044.
- [22]Liu Y, Fan T, Chen T, et al. Fate: An industrial grade platform for collaborative learning with data protection[J]. Journal of Machine Learning Research, 2021, 22(226): 1-6.

Public Copy Note

Statement page omitted

The original declaration and signature page is not included in this public copy.

This replacement page keeps the document pagination while avoiding personal fields.

致 谢

随着本科生涯的落幕，我想要向所有在这段旅程中给予我支持与帮助的人表达我最深切的感激之情。

我要对我的导师于海宁教授表示衷心的感谢。在论文的选题、撰写以及修改阶段，导师的专业指导和建议对我至关重要。于老师的严谨学术态度和悉心指导，对我学术上的成长起到了不可磨灭的影响。

我还要感谢孙迎港学长在论文完成过程中的无私帮助。孙学长不仅在学术上提供了专业的意见，还在我遇到困难时给予了我鼓励 and 信心，使我能够更加顺利地完成论文的撰写。

我要向我的家人表达感激之情。正是他们的理解与支持，使我得以全心投入学业；正是他们无条件的爱与鼓励，成为我面对困难时坚定不移的动力。

我也要对我的同学和朋友们表达感谢。在我的大学生活中，他们的陪伴和支持不仅让我的学习之路不再孤单，也使我的校园生活变得更加精彩多姿。

感谢学校提供的学术资源和优良的学习环境，使我能够顺利完成我的学业。对所有授课老师的辛勤付出和知识传授，我表示由衷的感谢。感谢秦海滨辅导员，每当我遇到困难和困惑时，总是耐心倾听并给予我宝贵的建议。

最后，我同样感谢我自己。在面对无数挑战和难题时，我始终没有选择退缩，而是不断地努力和坚持，追求更深的知识和个人的成长。这种自我驱动的精神不仅帮助我跨越了一个又一个障碍，也塑造了一个更坚韧、更成熟的我。

对于所有给予我帮助的人，我将永远铭记在心。在未来的道路上，我将带着你们的期望和祝福，继续前进，不断追求卓越。